



INFORME FINAL TALLER 1

Presentado por:

Cristian Camilo Llanos Alvarez - 1943852
Anderson Johan Alban Angulo - 2310006
Gustavo Adolfo Arango Nieves - 2310133
Juan Esteban Clavijo García - 2225709
Jhoan Felipe Leon Correa - 2228527

Presentado a:

RAUL ERNESTO GUTIERREZ DE PIÑEREZ REYES

Materia:

INT. A PROCESAMIENTO DE LENGUAJE NATURAL - 750108M

UNIVERSIDAD DEL VALLE
FACULTAD DE INGENIERÍA
Santiago de Cali
Marzo de 2026

Introducción

El presente informe tiene como objetivo evaluar el desempeño de tres arquitecturas de aprendizaje profundo: BiLSTM, BiLSTM-Deep y BiLSTM-CRF.

La tarea de POS tagging consiste en asignar etiquetas gramaticales a cada palabra dentro de una oración, lo cual representa un problema de **etiquetado secuencial**, donde el contexto y la dependencia entre palabras juegan un rol fundamental.

Se utilizaron los datasets **Ancora** y **CoNLL2002**, evaluando los modelos mediante métricas estándar: Accuracy, Precision, Recall y F1-score.

1. Modelos Evaluados

En este trabajo se evaluaron tres modelos de redes neuronales diseñados para entender el contexto de las palabras dentro de una oración y asignarles su etiqueta gramatical correspondiente.

- **BiLSTM (modelo base):** Este modelo analiza cada oración de izquierda a derecha y de derecha a izquierda, esto le permite entender mejor el contexto de cada palabra, por ejemplo:
 - La palabra “*bajo*” puede significar cosas distintas dependiendo de lo que viene antes y después. En términos simples, es como leer una oración completa antes de decidir qué significa cada palabra.

- Arquitectura:

Embedding* → *BiLSTM* → *Linear* → *Softmax

- **BiLSTM-Deep:** Este modelo es una versión mejorada del anterior. Después de entender el contexto con la BiLSTM, se agregan **capas adicionales (densas)** que permiten al modelo:

- Detectar patrones más complejos
- Refinar mejor las decisiones

No solo entiende la oración, sino que también “piensa un poco más” antes de decidir la etiqueta, es como alguien que no responde de inmediato, sino que analiza más profundamente.

- Arquitectura:

Embedding* → *BiLSTM* → *Linear* → *ReLU* → *Linear* → *Softmax

Embedding* → *BiLSTM* → *Linear* → *ReLU* → *Dropout* → *Linear* → *Softmax

- **BiLSTM-CRF:** Este modelo añade una capa extra llamada **CRF**, que tiene un objetivo distinto el cual es no solo clasificar palabras individualmente, sino que también:
 - Considera la relación entre etiquetas consecutivas
 - Intenta que toda la secuencia tenga sentido gramatical

Por lo que no decide palabra por palabra, sino que arma toda la frase de manera coherente, por ejemplo:

- o Es más probable que un determinante sea seguido por un sustantivo
- o El modelo aprende este tipo de reglas automáticamente

2. Resultados Generales

2.1 Dataset Ancora

Modelo	Accuracy	Precision	Recall	F1-score
BiLSTM	0.9591	0.95	0.88	0.903
BiLSTM-Deep	0.9563	0.96	0.96	0.9563
BiLSTM-CRF	0.9619	0.97	0.88	0.91

3.2 Dataset CoNLL2002

Modelo	Accuracy	Precision	Recall	F1-score
BiLSTM	0.9450	0.93	0.90	0.911
BiLSTM-Deep	0.9416	0.94	0.94	0.9389
BiLSTM-CRF	0.9497	0.9376	0.8832	0.8990

4. Análisis de Resultados

4.1 Análisis en dataset Ancora

Mejor modelo en F1-score: BiLSTM-Deep (0.9563)

Aunque el BiLSTM-CRF tiene mayor **Accuracy (0.9619)**, el mejor equilibrio entre precisión y recall lo logra **BiLSTM-Deep**.

- **BiLSTM-Deep logra el mejor Recall (0.96)** lo que quiere decir que detecta más correctamente las etiquetas reales, su F1-score es significativamente superior (+5% vs BiLSTM). Lo que indica que **las capas profundas ayudan a capturar patrones más complejos del lenguaje**. Esto ocurre porque las capas densas adicionales permiten transformar la información contextual generada por la BiLSTM en representaciones más complejas. De esta forma, el modelo no solo entiende el contexto, sino que también lo procesa en mayor profundidad antes de tomar una decisión, lo que mejora su capacidad de generalización frente a ejemplos no vistos.
- **El comportamiento del BiLSTM-CRF** nos dice que aunque tiene mejor Accuracy y Precision (0.97), tiene un **Recall bajo de (0.88)**, lo que nos sugiere que el modelo es muy preciso cuando predice pero **pierde etiquetas reales**. Por lo tanto, CRF está siendo más conservador, priorizando secuencias altamente probables, pero sacrificando cobertura.

4.2 Análisis en dataset CoNLL2002

Mejor modelo en F1-score: BiLSTM-Deep (0.9389)

Nuevamente, el modelo por profundidad domina, en la siguiente tabla hacemos un resumen que nos ayuda a entender de forma rápida y general el comportamiento de los modelos:

Modelo	Observación
BiLSTM	Balanceado pero menor rendimiento
BiLSTM-Deep	Mejor equilibrio global
BiLSTM-CRF	Mayor Accuracy pero peor F1

Podemos notar un **caso crítico** con el modelo **BiLSTM-CRF** ya que su accuracy es el más alto con 0.9497 pero es el que peor F1-score presenta con **0.8990**, Lo que nos hace concluir que hay un desbalance entre precision y recall.

Aunque el modelo BiLSTM-CRF obtiene la mayor accuracy, esta métrica no siempre refleja el desempeño real del modelo en tareas de clasificación multiclase. La accuracy puede verse influenciada por clases dominantes, mientras que el F1-score considera tanto la precisión como el recall. Por esta razón, el F1-score es una métrica más adecuada en este contexto, ya que permite evaluar el equilibrio entre detectar correctamente las etiquetas y evitar errores.

4.3 Comparación Global

Modelo	Comportamiento
BiLSTM	Base sólida
BiLSTM-Deep	Mejor modelo global
BiLSTM-CRF	Alta precisión, baja cobertura

4.4 Análisis por Etiqueta (Class-wise)

Anexo Tabla de resultado

Además del análisis global, es importante examinar el desempeño de los modelos a nivel de etiqueta, ya que esto permite identificar en qué tipos de palabras cada modelo presenta fortalezas o debilidades.

Con Ancora:

En el dataset Ancora se observa que:

- Las etiquetas más frecuentes como **NOUN**, **VERB**, **ADP**, **PRON** y **AUX** presentan valores altos de F1-score en todos los modelos (cerca de 0.90 - 1.00). Esto ocurre porque estas clases aparecen con mayor frecuencia en

el dataset, lo que permite al modelo ver más ejemplos durante el entrenamiento y aprender mejor sus patrones contextuales.

Sin embargo, aparecen diferencias importantes en etiquetas menos frecuentes:

- **SYM e INTJ presentan F1-scores bajos**, por ejemplo:
 - SYM (BiLSTM): $F1 \approx 0.51$
 - INTJ (BiLSTM-Deep): $F1 \approx 0.40$

Esto se debe a que estas etiquetas:

- Aparecen muy pocas veces en el dataset
- Tienen menor cantidad de ejemplos para aprender
- Pueden presentar mayor variabilidad en su uso

Como consecuencia, el modelo no logra generalizar correctamente para estas clases.

En este sentido, se evidencia un problema de **desbalance de clases**, donde las etiquetas menos frecuentes son más difíciles de aprender, ya que el modelo tiende a optimizar su desempeño hacia las clases dominantes.

Con CoNLL2002:

En CoNLL2002 se observa un comportamiento aún más marcado debido a la gran cantidad de etiquetas y su variabilidad.

Etiquetas con desempeño alto

- Puntuación (Fc, Fp, Fpt, etc.) $\rightarrow F1 \approx 1.00$

Esto se debe a que los signos de puntuación presentan formas fijas y funciones muy definidas dentro de la oración, lo que reduce la ambigüedad. A diferencia de otras categorías gramaticales, su identificación depende principalmente de su forma superficial, facilitando su aprendizaje por parte del modelo.

- Determinantes y conectores $\rightarrow$ desempeño casi perfecto

Esto ocurre porque:

- Son altamente frecuentes en el dataset
- Tienen patrones muy consistentes (poca ambigüedad)
- Su contexto es fácil de identificar

Etiquetas problemáticas

Se identifican etiquetas con bajo desempeño en todos los modelos:

- **VMM (verbo modal)**
- **VMG (gerundio)**
- **Y (símbolos especiales)**

Esto se debe a:

- **Alta ambigüedad lingüística** (pueden aparecer en múltiples contextos)
- **Baja frecuencia** en el dataset
- **Mayor complejidad morfológica** (especialmente en verbos)

Por ejemplo, los verbos pueden cambiar según tiempo, modo y persona, lo que dificulta su correcta clasificación.

Esta variabilidad genera un mayor número de combinaciones posibles, lo que dificulta que el modelo aprenda patrones consistentes, especialmente cuando algunas formas aparecen con poca frecuencia en el dataset.

Comparación entre modelos por etiqueta

BiLSTM-Deep

- Mejora el F1-score en muchas etiquetas
- Maneja mejor clases intermedias (ej: AQ, NC, VERB)

Indica mejor capacidad de generalización

BiLSTM-CRF

Presenta un patrón muy interesante:

- Alta precisión en muchas etiquetas
- Pero bajo recall en etiquetas complejas

Ejemplos claros:

- DT en CoNLL2002:
 - o Precision = 1.00
 - o Recall = 0.20
 - o F1 = 0.33

El CRF predice sólo cuando está muy seguro, pero deja muchos casos sin detectar.

Conclusión del análisis por etiquetas

El análisis por etiqueta confirma lo observado en las métricas globales:

- Los modelos funcionan muy bien en etiquetas frecuentes y estructuralmente simples
- Fallan en etiquetas raras, ambiguas o con poca representación

Además, el modelo BiLSTM-Deep logra el mejor equilibrio entre precisión y recall en la mayoría de las etiquetas, mientras que el modelo BiLSTM-CRF tiende a ser más conservador, afectando negativamente el recall en clases complejas.

5. Entonces, ¿el CRF ayudó realmente?

Teóricamente, la incorporación de una capa CRF debería mejorar el desempeño en tareas de etiquetado secuencial, ya que:

- Modela dependencias entre etiquetas
- Asegura coherencia secuencial en las predicciones

Sin embargo, en la práctica, los resultados obtenidos muestran que el modelo **BiLSTM-CRF no supera al modelo BiLSTM-Deep**, presentando un **Recall consistentemente bajo**, lo que impacta negativamente el F1-score.

Una posible explicación de este comportamiento es el fenómeno de **sobreajuste a secuencias frecuentes**.

El CRF aprende no sólo las etiquetas, sino también las **transiciones más probables entre ellas**, lo que implica que el modelo tiende a favorecer las estructuras más comunes observadas durante el entrenamiento; por ejemplo, determinante seguido de sustantivo.

Si bien esto mejora la coherencia de las predicciones, también provoca que el modelo:

- Sea más conservador en sus predicciones

Este comportamiento se explica porque el CRF optimiza la probabilidad de secuencias completas de etiquetas, favoreciendo aquellas combinaciones que ha observado con mayor frecuencia durante el entrenamiento. Como resultado, evita asignar etiquetas en contextos inciertos, lo que reduce errores en algunos casos, pero también disminuye la capacidad de detectar ejemplos válidos menos comunes.

- Evite asignar etiquetas menos frecuentes o ambiguas
- Pierda capacidad de generalización

Como consecuencia, el modelo puede fallar al reconocer correctamente etiquetas válidas en contextos menos comunes, reduciendo el Recall.

En este sentido, el CRF actúa como un mecanismo que prioriza la consistencia estructural sobre la cobertura de casos, lo que explica por qué, a pesar de obtener buenos valores de accuracy o precision, su desempeño global medido mediante F1-score resulta inferior al del modelo BiLSTM-Deep.

6. Conclusiones

A partir de los resultados obtenidos en los datasets Ancora y CoNLL2002, se concluye que el modelo **BiLSTM-Deep** fue el que presentó el mejor desempeño global, al alcanzar los mayores valores de F1-score en ambos conjuntos de datos.

Esto indica que la incorporación de capas densas adicionales permitió al modelo aprender representaciones más ricas y discriminativas, mejorando su capacidad de generalización frente a diferentes contextos lingüísticos.

Aunque el modelo **BiLSTM-CRF** obtuvo los mayores valores de accuracy, su desempeño global no fue el mejor, debido a que presentó valores de recall más bajos y, en consecuencia, F1-scores inferiores al modelo profundo. Esto sugiere que, si bien la capa CRF aporta coherencia secuencial al modelar dependencias entre etiquetas, también puede volver al modelo más conservador, favoreciendo secuencias frecuentes y reduciendo su capacidad para reconocer casos menos comunes o más ambiguos.

El análisis por etiqueta confirmó que los tres modelos funcionan muy bien en clases frecuentes y poco ambiguas, como puntuación, determinantes y algunas categorías funcionales, ya que estas presentan patrones más consistentes y fáciles de aprender. En contraste, las etiquetas menos frecuentes, ambiguas o morfológicamente complejas, como algunas categorías verbales, símbolos e interjecciones, mostraron un desempeño más bajo, evidenciando el efecto del desbalance de clases y de la variabilidad lingüística sobre el aprendizaje.

En conjunto, los resultados muestran que en esta tarea no basta con modelar dependencias secuenciales, sino que también es fundamental contar con una representación interna suficientemente rica para capturar la complejidad del lenguaje. En este experimento, la estrategia más efectiva fue aumentar la capacidad representacional del modelo mediante profundidad adicional, lo que permitió un mejor equilibrio entre precisión y recall.

Finalmente, puede concluirse que el modelo **BiLSTM-Deep** fue la mejor alternativa para este taller, ya que ofreció el rendimiento más sólido y balanceado en ambos datasets. Esto demuestra que, para la tarea de POS tagging en español evaluada en este trabajo, la profundidad del modelo resultó más beneficiosa que la imposición de restricciones estructurales mediante CRF.